Levantamento de Parâmetros e Tipagem de Dados

Nov 7, 2026 · @Gustavo Cruz

Painel Epidemiológico de Mortalidade Materna e Violência Obstétrica (SIM + SINASC, 2019–2024). Os microdados chegam como **CSV compactado em .zip**, localizados por uma **API de dados abertos (JSON)**. Cerca de 25 milhões de registros (~1,2 GB zipado) são reduzidos a **158 MB no PostgreSQL** por recorte temporal, seleção de colunas e agregação prévia no ETL.

1. Identificação da Fonte

O formato de origem dos microdados é **CSV** (separador `;`, codificação latin-1) **dentro de arquivos .zip**, um por ano. Os arquivos são localizados por **API de dados abertos** (CKAN, resposta em **JSON**), sem links fixos no código. **Parquet** não é formato de origem: é gerado pelo próprio ETL como camada intermediária (`data/processed`).

Fonte	Conteúdo	Formato de origem	Volume (2019–2024)	Como a ingestão lê
SIM – Sistema de Informação sobre Mortalidade	1 linha por óbito, ~90 colunas	CSV em .zip (81–107 MB/ano)	9.276.519 óbitos	blocos de 250 mil linhas direto do .zip
SINASC – Sistema de Informação sobre Nascidos Vivos	1 linha por nascimento, ~60 colunas	CSV em .zip (92–115 MB/ano)	15.745.110 nascidos vivos	blocos de 250 mil linhas direto do .zip
API CKAN do Portal de Dados Abertos do SUS	metadados: URL do arquivo, data de modificação, licença	JSON (`package_show`)	2 conjuntos (`sim` e `sistema-de-informacao-sobre-nascidos-vivos-sinasc`)	requisição HTTP; guardado em JSONB para a carga incremental

Fonte	Conteúdo	Formato de origem	Volume (2019–2024)	Como a ingestão lê
API de Localidades do IBGE	municípios, UFs e regiões	JSON	5.571 municípios	requisição HTTP; vira a dimensão de localidade
Tabela CID-10 do DATASUS	descrição textual das causas de morte	CSV em .zip	12.451 subcategorias	leitura única; vira dimensão e texto de busca

No total são cerca de **25 milhões de registros**, ~1,2 GB compactado e ~8 GB descompactado. SIM e SINASC são publicados sob licença **Creative Commons Atribuição (CC-BY)** e já vêm anonimizados pelo Ministério da Saúde.

A cada execução, a ingestão consulta a API, rejeita bases marcadas como “preliminar”, baixa o arquivo em streaming (blocos de 8 MB, com novas tentativas) e calcula o hash SHA-256. No modo incremental, compara a data de modificação informada pela API com a última carga e só reprocessa os anos republicados.

2. Estratégia de Otimização de Volume

Ação adotada: recorte temporal + agregação prévia durante o ETL. A amostragem estatística existe, mas só para testes rápidos, porque indicadores raros como a morte materna (10.556 casos em 6 anos) perderiam precisão se amostrados. Com isso, ~8 GB de CSV viram **157,8 MB no banco: 15% do limite de 1 GB** do PostgreSQL gratuito da Aiven.

Técnica	Como é aplicada no ETL	Efeito no volume
Recorte temporal	Apenas 2019–2024, as bases consolidadas mais recentes; 2025 é preliminar e fica fora por padrão	Limita a 6 anos de dados
Recorte de escopo	No SIM, óbitos fetais são excluídos; só as mortes maternas (12.080) são guardadas como registro individual	Dos 9,28 milhões de óbitos, só 0,13% vira linha individual
Seleção de colunas	20 das ~90 colunas do SIM e 15 das ~60 do SINASC; as demais são descartadas no próprio bloco (também exigência da LGPD)	78% das colunas do SIM e 75% das do SINASC descartadas

Técnica	Como é aplicada no ETL	Efeito no volume
Leitura em blocos (*chunking*)	Pandas lê 250 mil linhas por vez direto do .zip, sem descompactar em disco	Memória constante, independe do tamanho do arquivo
Agregação prévia	Nascimentos e óbitos viram contagens no grão ano × município × raça/cor × faixa etária	25 milhões de registros → 591.526 linhas na tabela fato
Generalização	Idade → faixa quinquenal; data → ano; nos registros individuais, município → UF	Menos valores distintos, índices menores
Tipos compactos	Ano em `smallint`, contagens em `integer`, códigos curtos em `varchar`	Menos bytes por coluna
Amostragem estatística (opcional)	Variável `ETL_AMOSTRA` (ex.: 0,1 = 10%), sorteio com semente fixa 42 para ser reproduzível; padrão 1,0 = sem amostragem	Usada só em testes e desenvolvimento
Monitoramento	Ao fim de cada carga, `verificar_tamanho()` mede cada tabela e alerta acima de 80% do limite	Evita estourar o plano gratuito

Tamanho final de cada tabela no Aiven for PostgreSQL, medido após a carga de 07/11/2026:

Tabela	Linhas	Tamanho (com índices)
`fato_saude_materna`	591.526	125,7 MB
`fato_obito_materno`	12.080	12,7 MB
`fato_obito_idade_reprodutiva`	70.885	7,8 MB
Dimensões e controle (12 tabelas)	—	2,7 MB
Total		**157,8 MB (15% de 1 GB)**

3. Mapeamento de Variedade e Tipagem

Os CSVs são lidos com **todas as colunas como texto** (`dtype=str`), para que zeros à esquerda e códigos não sejam corrompidos na leitura. A tipagem é feita depois, coluna a coluna, pelas funções da regra RN-00 (`etl/regras_negocio.py`). Antes disso, os nomes das colunas são padronizados em `snake_case` minúsculo (`DTOBITO` → `dtobito`).

Variedade dos dados

Tipo	Dado	Destino
Estruturado	Microdados do SIM e do SINASC (CSV)	Tabelas fato e dimensão do PostgreSQL
Semiestruturado	Metadados da API CKAN e municípios do IBGE (JSON); cadeia de causas da Declaração de Óbito (`*O149*R571`)	Coluna `JSONB` no PostgreSQL e documento aninhado no OpenSearch
Não estruturado	Descrição textual das causas (CID-10)	Índice de busca textual (`tsvector` em português e analisador `brazilian` no OpenSearch)

Colunas convertidas

Coluna de origem	Sistema	Tipo de origem	Tipo final	Regra de conversão
`DTOBITO` , `DTNASC`	SIM, SINASC	texto `DDMMAAAA`	inteiro (`smallint` , ano)	extrai os 4 últimos dígitos; ano diferente do arquivo é contabilizado no relatório de qualidade
`IDADE`	SIM	texto codificado (3 dígitos)	inteiro (anos) → faixa etária	1º dígito = unidade (4 = anos, 5 = 100+): `425` → 25 anos, `501` → 101 anos; acima de 120 → nulo

Coluna de origem	Sistema	Tipo de origem	Tipo final	Regra de conversão
`IDADEMAE`	SINASC	texto	inteiro → faixa etária	válido de 8 a 70 anos; fora disso → nulo (faixa “Ignorada”)
`PESO`	SINASC	texto (gramas)	inteiro	válido de 300 a 6.500 g; fora → nulo
`SEMAGESTAC`	SINASC	texto	inteiro (semanas)	válido de 20 a 45; fora → nulo
`APGAR5`	SINASC	texto	inteiro	válido de 0 a 10
`MESPRENAT`	SINASC	texto	inteiro (mês de início do pré-natal)	válido de 1 a 9
`TPROBSON`	SINASC	texto	inteiro (grupo de Robson)	válido de 1 a 10; 1–4 = gestação de baixo risco
`RACACOR`, `RACACORMAE`, `SEXO`, `ESC2010`, `LOCOCOR`, `ASSISTMED`, `NECROPSIA`, `TPMORTEOCO`	SIM, SINASC	texto (código)	categoria validada (`varchar`)	remove espaços e zeros à esquerda; código fora do dicionário → `9` (Ignorado)
`PARTO`, `CONSULTAS`, `KOTELCHUCK`, `GESTACAO`, `STCESPARTO`, `LOCNASC`	SINASC	texto (código)	indicador 0/1 somado em `integer`	ex.: `PARTO = 2` → cesárea = 1; código ignorado ou inválido sai só do denominador daquele indicador
`CODMUNRES`	SIM, SINASC	texto	código IBGE `char(6)`	validado contra a API do IBGE; inexistente com UF válida → `UU0000` (município ignorado da UF)

Coluna de origem	Sistema	Tipo de origem	Tipo final	Regra de conversão
`CAUSABAS`	SIM	texto (CID-10)	categoria (tipo obstétrico e grupo de causa)	maiúsculas; classificada pela regra RN-02 (direta, indireta, tardia)
`LINHAA` a `LINHAD`, `LINHAII`	SIM	texto semiestruturado (`*0149*R571`)	lista de CIDs em `JSONB`	`*0149*R571` → `["0149", "R571"]`; sufixo `X` removido
Descrições da CID-10	DATASUS	texto livre	`tsvector`	minúsculas, sem acento, dicionário português
Medidas agregadas (nascidos vivos, óbitos, cesáreas…)	ETL	contagem calculada	`integer` (int32)	célula sem evento → 0
Identificador do óbito	ETL	hash de 64 bits da linha	texto (`AAAA-hex`)	substitui o número da Declaração de Óbito (LGPD)

A base não tem valores monetários. O caso equivalente ao exemplo “string de valor monetário → decimal” é a conversão de texto numérico (peso, idade, semanas, Apgar) para inteiro, com **validação de faixa plausível**. Valor fora da faixa vira nulo e sai **só do denominador daquele indicador**, nunca do total de nascidos vivos.

Fontes: Portal de Dados Abertos do SUS (SIM e SINASC), API de Localidades do IBGE, CID-10 DATASUS. Código do ETL: github.com/GustavoCruzzz/painel-mortalidade-materna.