Entrega Técnica Fase 2 – Tratamento, Modelagem e Armazenamento

Nov 7, 2026 · @Gustavo Cruz

Painel Epidemiológico de Mortalidade Materna e Violência Obstétrica. Os microdados do SIM e do SINASC (2019–2024) foram tratados por um pipeline em Python e estão armazenados no Aiven for PostgreSQL, em esquema estrela, com um índice de busca no Aiven for OpenSearch.

1. Base de Dados Tratada

Origem dos dados

Os microdados vêm do **Portal de Dados Abertos do SUS** (Ministério da Saúde), licença Creative Commons Atribuição. O ETL descobre cada arquivo pela API CKAN do portal (conjuntos `sim` e `sistema-de-informacao-sobre-nascidos-vivos-sinasc`) e baixa do repositório oficial em `s3.sa-east-1.amazonaws.com/ckan.saude.gov.br`. Três bases auxiliares completam o tratamento: a API de Localidades do IBGE (5.571 municípios), a tabela CID-10 do DATASUS (12.451 subcategorias) e os dicionários de dados do SIM e do SINASC.

Versão original utilizada

Cada arquivo é identificado pela data de publicação informada pela API e pelo hash **SHA-256** calculado no download, ambos gravados na tabela `etl_execucao`. Isso permite provar exatamente qual versão foi usada, já que o Ministério republica os arquivos quando revisa óbitos investigados.

Sistema	Ano	Arquivo	Publicado em	SHA-256 (início)	Linhas originais
SIM	2019	`Mortalidade_Geral_2019_csv.zip`	14/09/2026	`66501b7348ad77d8`	1.349.801
SIM	2020	`Mortalidade_Geral_2020_csv.zip`	14/09/2026	`ac626dff18876eaa`	1.556.824
SIM	2021	`Mortalidade_Geral_2021_csv.zip`	14/09/2026	`6a8fe8077cf11cbf`	1.832.649
SIM	2022	`Mortalidade_Geral_2022_csv.zip`	29/10/2026	`b8fb61ab39b2408b`	1.544.266
SIM	2023	`Mortalidade_Geral_2023_csv.zip`	29/10/2026	`4409b41e945506fb`	1.465.610
SIM	2024	`Mortalidade_Geral_2024_csv.zip`	11/11/2025	`a68437fc88d7e3be`	1.527.369
SINASC	2019	`SINASC_2019_csv.zip`	08/05/2026	`4d528a8b6338ac3d`	2.849.146
SINASC	2020	`SINASC_2020_csv.zip`	08/05/2026	`d06af4961ab021cf`	2.730.145

Sistema	Ano	Arquivo	Publicado em	SHA-256 (início)	Linhas originais
SINASC	2021	`SINASC_2021_csv.zip`	08/05/2026	`240eb1f03aa9cb5e`	2.677.101
SINASC	2022	`SINASC_2022_csv.zip`	08/05/2026	`89e6f791a2470588`	2.561.922
SINASC	2023	`SINASC_2023_csv.zip`	08/05/2026	`c4ce57f7aa539023`	2.537.576
SINASC	2024	`SINASC_2024_csv.zip`	08/05/2026	`27e55de6359e1b19`	2.389.325

Total original: **25.021.734 linhas** em 12 arquivos CSV (separador `;`, latin-1), cerca de 1,2 GB compactados e 8 GB descompactados, com ~90 colunas no SIM e ~60 no SINASC.

Versão resultante

O resultado é um **esquema estrela** com 3 tabelas fato e 11 dimensões no Aiven for PostgreSQL, ocupando 158 MB, mais um índice de 12.080 documentos no Aiven for OpenSearch. A mesma versão tratada fica salva em **Parquet**, particionada por ano (13 MB).

Tabela resultante	Grão (o que é uma linha)	Linhas
`fato_saude_materna`	ano × município × raça/cor da mãe × faixa etária da mãe	591.526
`fato_obito_materno`	uma morte materna, anonimizada	12.080
`fato_obito_idade_reprodutiva`	ano × UF × sexo × raça/cor × faixa etária × grupo de causa (10–49 anos)	70.885

Os 25 milhões de linhas originais viraram **674.491 linhas** nas tabelas fato, uma redução de 97%, sem perder nenhum nascimento nem óbito do escopo: tudo continua contado nas agregações (15.745.110 nascidos vivos e 10.556 óbitos maternos).

Decisões de tratamento e justificativas

A regra geral foi **não descartar registros válidos**: um nascimento ou óbito com um campo ruim continua contado, e só aquele campo vira “Ignorado”. Descartar linhas inteiras enviesaria justamente os grupos com pior registro, que são os mais vulneráveis. Os números abaixo vêm do relatório de qualidade gravado a cada carga.

Decisão	Justificativa	Impacto medido (2019–2024)
Ler todas as colunas como texto e tipar depois	Evita que o Pandas transforme códigos como `01` em `1` ou em decimal	Nenhum código corrompido na leitura

Decisão	Justificativa	Impacto medido (2019–2024)
Padronizar nomes em `snake_case` minúsculo	Mesmos nomes no Python, no SQL e na documentação	`DTOBITO` → `dtobito`
Remover duplicatas por hash de 64 bits, inclusive entre blocos	Linhas idênticas inflariam as contagens; o hash permite comparar blocos sem guardar tudo em memória	112 linhas removidas no SIM e 105 no SINASC
Manter só 20 colunas do SIM e 15 do SINASC	Minimização exigida pela LGPD (art. 6º, III) e redução de volume	Datas exatas, estabelecimento, ocupação e naturalidade nunca são gravados
Código fora do dicionário → `9` (Ignorado)	Mantém o registro no total e torna a falta de informação visível no painel	Raça/cor da mãe ignorada em 445.202 nascimentos (2,8%)
Valor numérico fora da faixa plausível → nulo	Peso de 50 g ou idade de 300 anos são erro de digitação; o nulo sai só do denominador do indicador afetado	Total de nascidos vivos preservado
Município inexistente no IBGE → "município ignorado" da UF (`UU0000`)	O registro continua somando no estado e na região	14.601 óbitos e 453 nascimentos reatribuídos; nenhum descartado
Classificar a morte materna pelo CID-10 (regra RN-02)	Segue a definição da OMS: diretas, indiretas e não especificadas entram na RMM; tardias (O96–O97) não	10.556 óbitos maternos e 1.524 tardios
Excluir óbitos fetais	Morte materna é definida sobre óbito não fetal	0 encontrados: o arquivo de mortalidade geral já vem sem eles, mas a regra fica como proteção
Usar o ano do arquivo, não o da data do evento	É o padrão das estatísticas oficiais do Ministério	0 registros com data de outro ano
Rejeitar bases marcadas como "preliminar"	Dados ainda em investigação mudam depois e distorcem a série	2025 fica fora da carga padrão

Decisão	Justificativa	Impacto medido (2019–2024)
Agregar no grão ano × município × raça/cor × faixa etária	Cabe no limite de 1 GB, protege a privacidade e responde a todas as perguntas do painel com `SUM`	25 milhões de linhas → 591.526
Generalizar os registros individuais de morte materna	LGPD: em municípios pequenos, data + idade + local poderiam identificar a mulher	Idade → faixa, data → ano, município → UF, número da declaração → hash
Não usar amostragem na carga final	Morte materna é rara (cerca de 1.760 por ano); amostrar perderia precisão nos recortes por raça e UF	100% dos registros processados

2. Processo de Tratamento dos Dados

O processo é um pipeline em **Python 3 + Pandas**, versionado em github.com/GustavoCruzzz/painel-mortalidade-materna, pasta `etl/`. Um único comando reproduz toda a base: `python -m etl.pipeline --anos 2019-2024`. A carga completa levou cerca de 10 minutos.

Etapas, para cada ano

1. **Descoberta** – consulta a API CKAN, encontra o CSV do ano e rejeita bases preliminares.
2. **Download** – baixa em streaming (blocos de 8 MB, com novas tentativas) e calcula o SHA-256.
3. **Leitura em blocos** – lê 250 mil linhas por vez direto de dentro do .zip, sem descompactar em disco.
4. **Limpeza** – padroniza nomes, remove duplicatas, descarta colunas não usadas, converte tipos e normaliza códigos.
5. **Validação** – confere o município contra o IBGE e os códigos contra os dicionários.
6. **Regras de negócio** – classifica a morte materna, calcula faixas etárias e os indicadores de assistência (regras RN-00 a RN-10).
7. **Agregação e integração** – soma por ano × município × raça/cor × faixa e une SIM (numerador) e SINASC (denominador) na mesma tabela.
8. **Persistência em Parquet** – grava `data/processed/<tabela>/ano=AAAA.parquet`.

9. **Carga no PostgreSQL** – numa transação por ano: apaga o ano e insere de novo com `COPY`.
10. **Registro** – grava a versão da fonte e o relatório de qualidade em `etl_execucao`.

No fim, recria as views de indicadores, concede leitura ao usuário do dashboard, mede o tamanho do banco e indexa as mortes maternas no OpenSearch.

Onde está cada parte no repositório

Arquivo	Responsabilidade
`etl/pipeline.py`	Orquestra as etapas e aceita opções (`--anos`, `--incremental`, `--sem-opensearch`)
`etl/extract.py`	API CKAN, API do IBGE, tabela CID-10 e download com SHA-256
`etl/transform.py`	Leitura em blocos, deduplicação, limpeza, agregação do SIM e do SINASC
`etl/regras_negocio.py`	Conversão de tipos e regras RN-00 a RN-10
`etl/dominios.py`	Dicionários de códigos (raça/cor, faixas, escolaridade, grupos de causa)
`etl/load.py`	Criação das tabelas, carga com `COPY`, permissões, controle de volume e OpenSearch
`etl/sql/schema.sql`	Estrutura do banco: tabelas, chaves, `CHECK`s e índices
`etl/sql/views.sql`	Indicadores em SQL (RMM, risco relativo racial, indicadores obstétricos)
`etl/tests/`	25 testes automatizados das regras de negócio (pytest)
`.github/workflows/etl.yml`	Execução automática todo dia 5 de cada mês

Decisões técnicas do processo

Decisão	Justificativa
Pandas com leitura em blocos, e não PySpark	25 milhões de linhas cabem num computador comum se lidas em blocos; o Spark exigiria um cluster e não traria ganho nesse volume

Decisão	Justificativa
Agregar antes de carregar	O banco gratuito tem 1 GB; agregado, o resultado ocupa 158 MB (15%)
Parquet como camada intermediária	Formato colunar e compactado (13 MB); permite recarregar o banco sem reprocessar os CSVs
Carga com `COPY` numa transação por ano	`COPY` é a forma mais rápida de inserir no PostgreSQL; apagar e recarregar o ano torna a carga **idempotente**: rodar duas vezes não duplica dados
Modo incremental	Compara a data de publicação na API com a última carga e só reprocessa os anos republicados
Regras de negócio em funções testadas	Os 25 testes rodam a cada `git push` no GitHub Actions; uma mudança que quebre uma regra é barrada
Credenciais fora do código	As senhas ficam no `.env` local e nos Secrets do GitHub; o repositório é varrido pelo gitleaks a cada push

3. Base Armazenada em Banco de Dados

Estrutura criada

Os dados tratados estão em dois serviços gratuitos da **Aiven**, na região DigitalOcean Nova York, ambos criados por código com **Terraform** (`terraform/main.tf`):

Serviço	Plano	Papel	Conteúdo
Aiven for PostgreSQL 18	`free-1-1gb` (1 GB de disco)	Banco relacional, fonte da verdade de todas as métricas	Banco `saude_materna` , schema `saude_materna` : 3 fatos, 11 dimensões, 1 tabela de controle e 7 views
Aiven for OpenSearch 3	`free-4-20`	Banco não relacional, busca textual nas causas de morte	Índice `obitos-maternos` com 12.080 documentos JSON

Todas as conexões usam TLS. O ETL grava com o usuário administrador. O dashboard lê com o usuário `dashboard_leitor`, que só tem permissão de `SELECT`: uma tentativa de `DELETE` com ele é recusada pelo banco.

Por que esquema estrela

O painel responde sempre ao mesmo tipo de pergunta: somar nascimentos e óbitos filtrando por ano, território, raça/cor e idade. O **esquema estrela** (fatos com as contagens no centro, dimensões descritivas ao redor) é o modelo feito para isso.

Alternativa	Vantagem	Por que não foi a principal
Esquema estrela (escolhido)	Consultas simples (um `JOIN` por dimensão + `SUM`), filtros cruzados rápidos, integridade por chaves estrangeiras	—
Modelo normalizado (3FN) com uma linha por evento	Guarda o detalhe máximo	25 milhões de linhas não cabem em 1 GB e manter o detalhe fere a minimização da LGPD
Tabela única “achatada”	Nenhum `JOIN`	Repetiria nomes de município, UF e região em 591 mil linhas e não garantiria códigos válidos
Só banco não relacional	Esquema flexível	Sem chaves estrangeiras, transações nem `CHECK`s, a Veracidade dependeria só do código

Foram criadas **três tabelas fato** porque há três grãos diferentes de pergunta: indicadores por município (a principal), o detalhe de cada morte materna (causas e busca) e a comparação entre homens e mulheres de 10 a 49 anos (eixo de gênero).

O **OpenSearch** complementa o PostgreSQL onde ele é mais fraco: busca por palavras com relevância (“eclampsia” encontra “eclâmpsia”) sobre documentos com listas aninhadas, como a cadeia de causas do atestado de óbito. O índice é derivado do PostgreSQL e pode ser recriado a qualquer momento.

Garantias de qualidade dentro do banco

- **Chaves primárias compostas** impedem duplicar uma combinação ano × município × raça/cor × faixa.
- **Chaves estrangeiras** impedem gravar um código de raça/cor, faixa ou município que não exista na dimensão.
- **`CHECK`s** impedem um numerador maior que o denominador (ex.: mais cesáreas do que partos informados).
- **Índices** em `(cod_uf, ano)` e `(cod_raca_cor, ano)` aceleram os filtros do painel, e índices GIN aceleram a busca no `JSONB` e no texto.

Principais tabelas, campos e tipos

PK = chave primária; FK = chave estrangeira. A estrutura completa está em `etl/sql/schema.sql`.

`fato_saude_materna` – indicadores por município. Une o denominador da RMM (nascidos vivos, do SINASC) e o numerador (óbitos maternos, do SIM).

Campo	Tipo	Chave / restrição	Descrição
`ano`	`SMALLINT`	PK, FK → `dim_tempo`	Ano do arquivo de origem
`cod_municipio`	`CHAR(6)`	PK, FK → `dim_localidade`	Município de residência (código IBGE)
`cod_raca_cor`	`VARCHAR(1)`	PK, FK → `dim_raca_cor`	Raça/cor da mãe (SINASC) ou da falecida (SIM)
`cod_faixa_etaria`	`VARCHAR(5)`	PK, FK → `dim_faixa_etaria`	Faixa etária quinquenal da mulher
`cod_uf`	`CHAR(2)`	coluna gerada, indexada	Dois primeiros dígitos do município
`nascidos_vivos`	`INTEGER`	`CHECK >= 0`	Total de nascidos vivos
21 contadores do SINASC: `partos_cesareos`, `cesareas_eletivas_baixo_risco`, `prenatal_inadequado`, `partos_fora_estabelecimento`, `apgar5_baixo`, `prematuros`, `baixo_peso` e outros	`INTEGER`	`CHECK` numerador ⩽ denominador	Cada indicador tem um numerador e um denominador de registros válidos (ex.: `partos_cesareos` / `partos_info_valida`)

Campo	Tipo	Chave / restrição	Descrição
7 contadores do SIM: `obitos_maternos`, `obitos_maternos_diretos`, `_indiretos`, `_tardios`, `obitos_sem_assistencia`, `obitos_fora_estabelecimento`, `obitos_investigados`	`INTEGER`	`CHECK` diretos + indiretos ⩽ total	Óbitos maternos e perfil de assistência

`fato_obito_materno` – uma linha por morte materna, anonimizada.

Campo	Tipo	Chave / restrição	Descrição
`id_obito`	`TEXT`	PK	Hash de 64 bits da linha original (substitui o número da declaração)
`ano`	`SMALLINT`	FK → `dim_tempo`	Ano do óbito
`cod_uf`	`CHAR(2)`	indexado	UF de residência (município omitido por privacidade)
`cod_raca_cor`, `cod_faixa_etaria`, `cod_escolaridade`	`VARCHAR`	FK → dimensões	Perfil da mulher
`causa_basica`, `causa_basica_descricao`	`VARCHAR(4)`, `TEXT`	—	CID-10 da causa básica e sua descrição
`tipo_obstetrico`, `grupo_causa`	`TEXT`	FK → dimensões	Direta / indireta / tardia; hipertensão, hemorragia, aborto…
`cod_momento_obito`, `cod_local_ocorrencia`, `cod_assistencia_medica`, `cod_necropsia`	`VARCHAR(1)`	—	Códigos do atestado, descritos em `dim_dominio`
`investigado`	`BOOLEAN`	—	Se o óbito foi investigado

Campo	Tipo	Chave / restrição	Descrição
`cadeia_causas`	`JSONB`	índice GIN	Causas de cada linha do atestado, ex.: `{"a": ["O149"], "b": ["R571"]}`
`texto_causas`	`TEXT`	—	Descrições de todas as causas, em texto livre
`tsv_causas`	`TSVECTOR`	coluna gerada, índice GIN	Texto preparado para busca em português, sem acentos

`fato_obito_idade_reprodutiva` – óbitos de 10 a 49 anos, de homens e mulheres, para o eixo de gênero.

Campo	Tipo	Chave / restrição	Descrição
`ano`, `cod_uf`, `cod_sexo`, `cod_raca_cor`, `cod_faixa_etaria`, `cod_grupo_causa`	`SMALLINT`, `CHAR(2)`, `VARCHAR`, `TEXT`	PK composta; FKs → dimensões	Recorte do grupo de óbitos
`n_obitos`	`INTEGER`	`CHECK > 0`	Quantidade de óbitos
`n_gestante_puerpera`	`INTEGER`	—	Quantos eram de gestantes ou puérperas

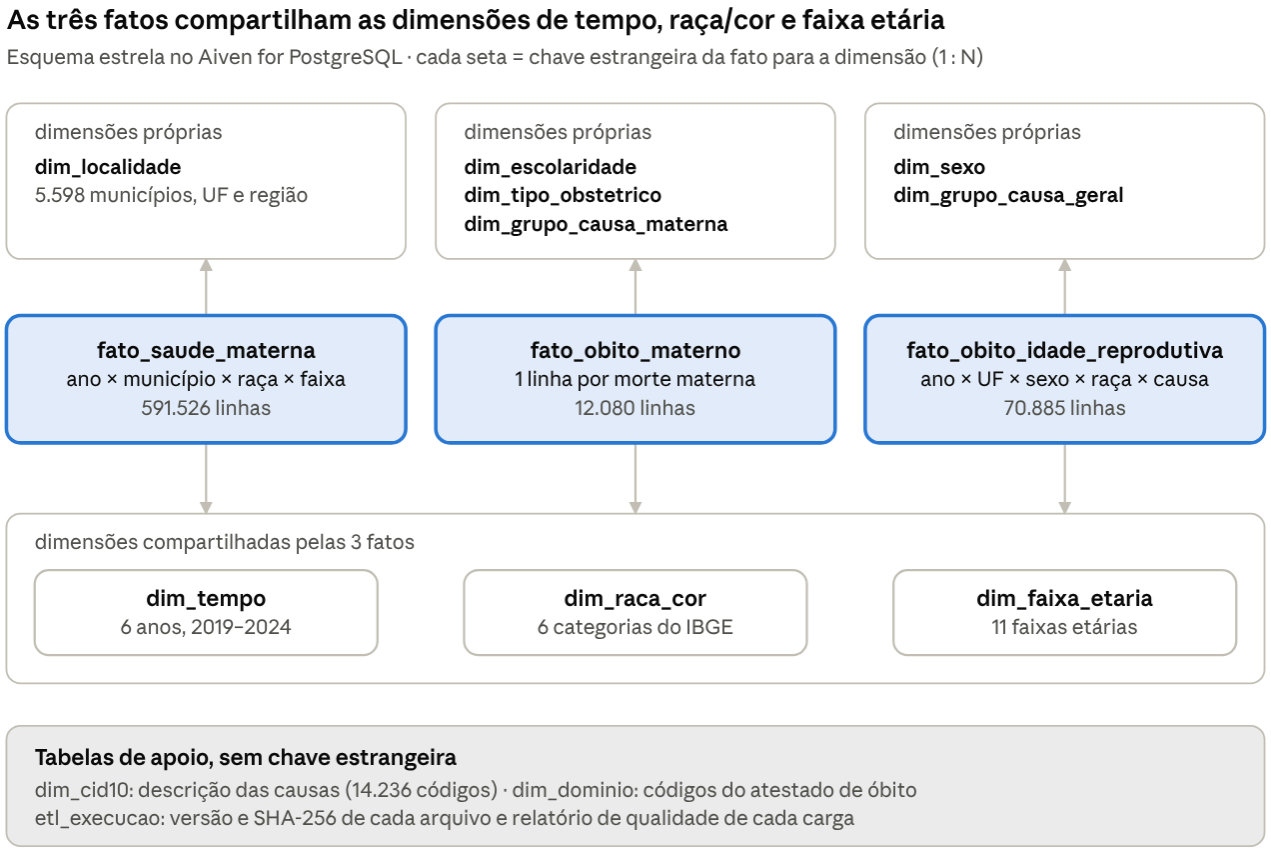
Dimensões e controle

Tabela	Chave primária	Demais campos
`dim_tempo`	`ano SMALLINT`	`periodo TEXT` (pré-pandemia, pandemia, pós-pandemia), `base_preliminar BOOLEAN`

Tabela	Chave primária	Demais campos
`dim_localidade`	`cod_municipio CHAR(6)`	`cod_municipio_ibge7 CHAR(7)`, `nome_municipio`, `cod_uf CHAR(2)`, `sigla_uf`, `nome_uf`, `sigla_regiao`, `nome_regiao`, `municipio_ignorado BOOLEAN`
`dim_raca_cor`	`cod_raca_cor VARCHAR(1)`	`descricao`, `grupo_ibge` (Negra = Preta + Parda)
`dim_faixa_etaria`	`cod_faixa_etaria VARCHAR(5)`	`descricao`, `idade_min SMALLINT`, `idade_max SMALLINT`, `ordem SMALLINT`
`dim_escolaridade`	`cod_escolaridade VARCHAR(1)`	`descricao`
`dim_sexo`	`cod_sexo VARCHAR(1)`	`descricao`
`dim_tipo_obstetrico`	`tipo_obstetrico TEXT`	`descricao`, `entra_rmm BOOLEAN`
`dim_grupo_causa_materna`	`grupo_causa TEXT`	`descricao`, `cids` (faixa de CIDs do grupo)
`dim_grupo_causa_geral`	`cod_grupo_causa TEXT`	`descricao`
`dim_dominio`	`(dominio, codigo)`	`descricao` (códigos de momento, local, sim/não)
`dim_cid10`	`cid VARCHAR(4)`	`descricao`
`etl_execucao`	`id BIGSERIAL`	`iniciado_em`, `finalizado_em TIMESTAMPTZ`, `sistema`, `ano`, `status`, `fracao_amostra NUMERIC(4,3)`, `relatorio JSONB` (qualidade), `fonte JSONB` (versão do arquivo e SHA-256)

Sete **views** ficam sobre as tabelas e guardam os indicadores já calculados em SQL: `vw_rmm_uf_raca` (RMM por UF e raça/cor), `vw_risco_relativo_racial`, `vw_indicadores_obstetricos`, `vw_obito_materno_detalhado`, `vw_fato_saude_materna`, `vw_qualidade_ultima_carga` e `vw_uf`.

Relacionamentos



esquema estrela · 3 fatos, 11 dimensões, 1 tabela de controle

Todos os relacionamentos são **1 : N**: uma linha da dimensão (por exemplo, a raça/cor "Preta") se liga a muitas linhas da fato. As três fatos não se ligam diretamente entre si; o cruzamento é feito pelas dimensões compartilhadas, então o mesmo filtro de ano, raça/cor e faixa etária vale para a RMM, para as causas de morte e para a comparação de gênero. `dim_cid10` e `dim_dominio` são consultadas pelo código, sem chave estrangeira, porque um CID raro ausente da tabela não pode impedir a carga de um óbito.

Quantidade de dados armazenados

O banco ocupa **158 MB, 15% do limite de 1 GB** do plano gratuito. As linhas foram contadas com `COUNT(*)` e o tamanho medido com `pg_total_relation_size` (dados + índices) no Aiven for PostgreSQL, após a carga de 07/11/2026.

Tabela	Tipo	Linhas	Tamanho
`fato_saude_materna`	fato	591.526	125,7 MB
`fato_obito_materno`	fato	12.080	12,7 MB
`fato_obito_idade_reprodutiva`	fato	70.885	7,8 MB

Tabela	Tipo	Linhas	Tamanho
`dim_cid10`	dimensão	14.236 (categorias e subcategorias)	1,9 MB
`dim_localidade`	dimensão	5.598 (5.571 municípios + 27 “ignorados”, um por UF)	0,7 MB
Outras 9 dimensões	dimensão	73 no total (ex.: 6 anos, 6 raças/cores, 11 faixas etárias)	0,2 MB
`etl_execucao`	controle	12 (SIM e SINASC × 6 anos)	0,1 MB
Total PostgreSQL		**694.410**	**158 MB**
Índice `obitos-maternos` (OpenSearch)	documentos	12.080	3,8 MB

Essas linhas contêm, de forma agregada, **todos os 15.745.110 nascidos vivos** (as linhas lidas menos 105 duplicatas) e todos os óbitos do escopo do projeto: as mortes maternas e os óbitos de pessoas de 10 a 49 anos. Os demais óbitos dos 9.276.519 lidos, de pessoas com menos de 10 ou mais de 49 anos que não sejam mortes maternas, ficam fora do escopo e não são armazenados.