# Entrega Marco 2 – Infraestrutura, Segurança, Repositório e Documentação

Nov 7, 2026 · @Gustavo Cruz

Painel Epidemiológico de Mortalidade Materna e Violência Obstétrica. Todos os entregáveis desta etapa estão no repositório github.com/GustavoCruzzz/painel-mortalidade-materna, e o dashboard está publicado em painel-mortalidade-materna.streamlit.app.

## Checklist da entrega

| Item pedido | Onde está | Situação |
|---|---|---|
| Repositório Git do projeto | github.com/GustavoCruzzz/painel-mortalidade-materna | Publicado, CI aprovado |
| Código do processo de tratamento | `etl/` | 8 módulos Python + SQL + 28 testes |
| Base de dados tratada | `dados_tratados/` | Fatos em Parquet, dimensões em CSV, manifesto com SHA-256 (11,8 MB) |
| Banco de dados com a carga realizada | Aiven for PostgreSQL `materna-pg` + OpenSearch `materna-os` | 694.410 linhas, 158 MB (15% de 1 GB), carga de 07/11/2026 |
| Infraestrutura provisionada por Terraform | `terraform/` | 6 recursos criados com `terraform apply` |
| Documentação atualizada no README | `README.md` | 17 seções, com mapa dos entregáveis no topo |
| Decisões técnicas e justificativas | README, seções 7, 9, 12 e 13; seção 8 deste documento | — |

# 4. Infraestrutura como código (Terraform)

Toda a camada de dados foi criada pelo Terraform, sem cliques no console: `terraform apply` criou 6 recursos em cerca de 6 minutos no projeto Aiven `ucsal-big-data-project`, região DigitalOcean Nova York (`do-nyc`), com custo zero.

| Recurso Terraform | Nome criado | O que é |
|---|---|---|
| `aiven_pg.pg` | `materna-pg` | PostgreSQL 18.6, plano `free-1-1gb`, TLS obrigatório |
| `aiven_pg_database.saude_materna` | `saude_materna` | Banco lógico do projeto |
| `random_password.leitor` | — | Senha aleatória de 32 caracteres |
| `aiven_pg_user.dashboard` | `dashboard_leitor` | Usuário somente leitura do dashboard |
| `aiven_opensearch.os[0]` | `materna-os` | OpenSearch 3.6, plano `free-4-20` |
| `local_sensitive_file.env[0]` | `.env` | Arquivo local com as URIs de conexão, fora do Git |

| Arquivo | Conteúdo |
|---|---|
| `terraform/main.tf` | Providers (`aiven/aiven ~> 4.0`, `random`, `local`) e recursos |
| `terraform/variables.tf` | Token (`sensitive`), projeto, planos, região, nomes, liga/desliga do OpenSearch |
| `terraform/outputs.tf` | Host, porta, banco, estado; URIs com senha marcadas `sensitive` |
| `terraform/terraform.tfvars.example` | Modelo das variáveis, sem valores reais |
| `terraform/.terraform.lock.hcl` | Versões exatas dos providers |

**Decisões.** O estado do Terraform (`terraform.tfstate`) fica fora do Git porque guarda as senhas em texto. O assistente da Aiven sugere no primeiro acesso um serviço pago (`developer-1`); esse serviço foi apagado e o Terraform criou os planos gratuitos. A variável `nome_servico_pg` permite trazer um serviço já existente para o Terraform com `terraform import`. O CI roda `terraform fmt` e `terraform validate` a cada push.

# 5. Segurança das informações

Nenhuma credencial está no repositório público. Cada segredo fica num cofre próprio e só chega a quem precisa dele; o repositório contém apenas modelos sem valores reais (`.env.example`, `terraform.tfvars.example`, `secrets.toml.example`).

| Credencial | Onde fica | Quem usa |
|---|---|---|
| Token da API da Aiven | `terraform/terraform.tfvars` local, ignorado pelo Git (ou variável `TF_VAR_aiven_api_token`) | Terraform |
| URI do administrador (`DATABASE_URL`) e do OpenSearch | `.env` local, ignorado, e **GitHub Actions Secrets** | ETL |
| URI do usuário somente leitura (`DASHBOARD_DATABASE_URL`) | `.streamlit/secrets.toml` local, ignorado, e **Streamlit Cloud Secrets** | Dashboard |
| Estado do Terraform (contém todas as senhas) | Só na máquina de quem provisionou, ignorado, com cópia privada | Terraform |

### Camadas de proteção

1. `.gitignore` bloqueia `.env`, `secrets.toml`, `terraform.tfvars`, `*.tfstate`, planos do Terraform e os microdados brutos.
2. O CI roda o **gitleaks** sobre todo o histórico do Git a cada push e falha se encontrar um token ou senha.
3. **Menor privilégio:** o dashboard público usa `dashboard_leitor`, que só pode fazer `SELECT`. A senha de administrador existe apenas no GitHub Actions.
4. **TLS obrigatório** em todas as conexões com a Aiven.
5. Saídas do Terraform com senha marcadas `sensitive`, que não aparecem no log.
6. SQL parametrizado no dashboard e nenhum dado pessoal identificável gravado (LGPD).

**Verificação feita em 07/11/2026:** `gitleaks` sobre os 6 commits e sobre `dados_tratados/` retornou “no leaks found”; `git ls-files` não lista nenhum `.env`, `tfstate` ou `tfvars`; um `DELETE` com `dashboard_leitor` no banco da Aiven foi recusado com `InsufficientPrivilege`.

O README (seção 13) também descreve o que fazer se uma credencial vazar: revogar o token, regenerar a senha do leitor com `terraform apply -replace` e trocar a senha do administrador no console.

# 6. Repositório do projeto

O repositório separa cada tipo de artefato numa pasta própria. As pastas em maiúsculas no comentário correspondem aos itens mínimos pedidos.

```
├── etl/                # TRATAMENTO: extração, limpeza, regras, carga
│   ├── sql/            # schema.sql (banco) e views.sql (indicadores)
│   └── tests/          # 28 testes automatizados
├── terraform/          # INFRAESTRUTURA: arquivos .tf e lock
├── dados_tratados/     # BASE TRATADA: Parquet, CSV, MANIFESTO.json
├── docs/               # DOCUMENTAÇÃO: PDFs das entregas
├── README.md           # DOCUMENTAÇÃO principal (17 seções)
├── dashboard/          # visualização (Streamlit), próxima fase
├── .github/workflows/ # REPRODUÇÃO: CI e ETL mensal
├── requirements.txt    # REPRODUÇÃO: dependências com versão fixa
├── .env.example        # modelo de variáveis, sem segredos
└── .gitignore          # bloqueia segredos, tfstate e dados brutos
```

Os microdados brutos (~1,2 GB) não são versionados: o ETL os baixa de novo da fonte oficial, e a versão exata usada fica registrada pelo SHA-256.

# 7. Documentação (README.md)

O README foi reorganizado para seguir os tópicos pedidos. No topo há uma tabela que leva a cada entregável do Marco 2.

| Tópico exigido | Seção do README | O que apresenta |
|---|---|---|
| **Dados utilizados:** fonte, identificação, período, características | 3. Dados utilizados | 4 fontes com identificador no portal; 2019–2024; volume, códigos, informação ignorada; tabela da versão original com SHA-256 |
| **Tratamento:** problemas, decisões, transformações, justificativas | 7. Tratamento realizado; 8. Processo de ingestão e ETL; 11. Regras de negócio | 8 problemas com quantidade; 14 decisões com justificativa e impacto; etapas do pipeline; regras RN-00 a RN-10 |

| Tópico exigido | Seção do README | O que apresenta |
|---|---|---|
| **Modelagem:** estrutura, estratégia, representação | 9. Modelagem; 10. Dicionário de dados | Diagrama do esquema estrela, comparação relacional × não relacional, campos e tipos, quantidade armazenada |
| **Infraestrutura:** serviços, recursos, tecnologias | 12. Infraestrutura | Serviços e planos, 7 recursos do Terraform (6 criados + 1 lido), arquivos, tecnologias com versão |
| **Execução:** ferramentas, reprodução, sequência | 15. Execução e reprodução | Ferramentas com versão, sequência em 7 passos, comandos para Linux e Windows, como destruir |
| Segurança | 13. Segurança da informação | Onde fica cada credencial, camadas de proteção, como verificar, o que fazer em caso de vazamento |

A pasta `dados_tratados/` tem um README próprio com o conteúdo de cada arquivo, e `docs/` guarda os PDFs das entregas anteriores.

## 8. Escolhas tecnológicas e justificativas

Cada escolha partiu de duas restrições da base: **25 milhões de linhas** de entrada e um banco gratuito de **1 GB**.

| Aspecto | Escolha | Alternativa considerada | Por que a escolha |
|---|---|---|---|
| Ferramenta de tratamento | Python + pandas | PySpark | O volume cabe num computador comum se lido em blocos; o Spark exigiria um cluster sem ganho real |

| Aspecto | Escolha | Alternativa considerada | Por que a escolha |
|---|---|---|---|
| Estratégia de processamento | Lote (*batch*) em blocos de 250 mil linhas, mensal e incremental | Streaming | A fonte é publicada uma vez por ano e revisada aos poucos; streaming não teria o que transmitir |
| Organização dos dados | Agregação prévia no grão ano × município × raça/cor × faixa | Guardar um registro por evento | Cabe em 15% do banco e atende à minimização da LGPD sem perder as análises do painel |
| Modelo de banco | Esquema estrela no PostgreSQL + índice no OpenSearch | Modelo 3FN; tabela única; só NoSQL | Consultas de soma com filtros cruzados são o caso típico do esquema estrela; chaves e `CHECK`s garantem a veracidade; o OpenSearch cobre a busca textual |
| Estrutura de código | Módulos por etapa (extract, transform, regras, load) + testes | Notebook único | Cada etapa é testada e reutilizada; o mesmo código roda local e no GitHub Actions |
| Armazenamento intermediário | Parquet por ano | CSV | Colunar, compactado e preserva os tipos das colunas; a base tratada inteira ocupa 13 MB |
| Infraestrutura | Aiven gratuita, provisionada por Terraform | Banco local; criar pelo console | Nuvem a custo zero, reproduzível e destruível com um comando |

## 9. Resultado do Marco 2

O fluxo pedido está completo, e a camada de dados já está sendo usada pela fase seguinte: o dashboard publicado lê o banco da Aiven.

| Etapa | Evidência |
|---|---|
| 1. Dados públicos selecionados | 12 arquivos do SIM e do SINASC 2019–2024, identificados por data de publicação e SHA-256 (README, seção 3) |
| 2. Dados preparados e tratados | 25.021.734 linhas lidas, 217 duplicatas removidas, 14 decisões de tratamento documentadas (seção 7) |
| 3. Dados organizados por modelagem definida | Esquema estrela com 3 fatos e 11 dimensões (seções 9 e 10) |
| 4. Dados armazenados em banco na nuvem | 694.410 linhas e 158 MB no Aiven for PostgreSQL; 12.080 documentos no OpenSearch |
| 5. Processo e infraestrutura documentados e versionados | `etl/`, `terraform/`, `dados_tratados/` e README no GitHub; CI aprovado no último commit |

O ETL também está agendado no GitHub Actions para todo dia 5 e, em modo incremental, só reprocessa os anos que o Ministério da Saúde republicar. A execução manual de 07/11/2026 passou: os 6 anos foram pulados porque a fonte não mudou desde a carga. Como o servidor do IBGE não responde a conexões de fora do Brasil, as tabelas do IBGE e da CID-10 ficam versionadas no repositório.