Entrega Marco 2 – Infraestrutura, Segurança, Repositório e Documentação

Nov 7, 2026 · @Gustavo Cruz

Painel Epidemiológico de Mortalidade Materna e Violência Obstétrica. Todos os entregáveis desta etapa estão no repositório github.com/GustavoCruzzz/painel-mortalidade-materna, e o dashboard está publicado em painel-mortalidade-materna.streamlit.app.

Checklist da entrega

Item pedido	Onde está	Situação
Repositório Git do projeto	github.com/GustavoCruzzz/painel-mortalidade-materna	Publicado, CI aprovado
Código do processo de tratamento	`etl/`	8 módulos Python + SQL + 25 testes
Base de dados tratada	`dados_tratados/`	Fatos em Parquet, dimensões em CSV, manifesto com SHA-256 (11,8 MB)
Banco de dados com a carga realizada	Aiven for PostgreSQL `materna-pg` + OpenSearch `materna-os`	694.410 linhas, 158 MB (15% de 1 GB), carga de 07/11/2026
Infraestrutura provisionada por Terraform	`terraform/`	6 recursos criados com `terraform apply`
Documentação atualizada no README	`README.md`	17 seções, com mapa dos entregáveis no topo
Decisões técnicas e justificativas	README, seções 7, 9, 12 e 13; seção 8 deste documento	—

4. Infraestrutura como código (Terraform)

Toda a camada de dados foi criada pelo Terraform, sem cliques no console: `terraform apply` criou 6 recursos em cerca de 6 minutos no projeto Aiven `ucsal-big-data-project`, região DigitalOcean Nova York (`do-nyc`), com custo zero.

Recurso Terraform	Nome criado	O que é
`aiven_pg.pg`	`materna-pg`	PostgreSQL 18.6, plano `free-1-1gb`, TLS obrigatório
`aiven_pg_database.saude_materna`	`saude_materna`	Banco lógico do projeto
`random_password.leitor`	—	Senha aleatória de 32 caracteres
`aiven_pg_user.dashboard`	`dashboard_leitor`	Usuário somente leitura do dashboard
`aiven_opensearch.os[0]`	`materna-os`	OpenSearch 3.6, plano `free-4-20`
`local_sensitive_file.env[0]`	`.env`	Arquivo local com as URIs de conexão, fora do Git

Arquivo	Conteúdo
`terraform/main.tf`	Providers (`aiven/aiven ~> 4.0`, `random`, `local`) e recursos
`terraform/variables.tf`	Token (`sensitive`), projeto, planos, região, nomes, liga/desliga do OpenSearch
`terraform/outputs.tf`	Host, porta, banco, estado; URIs com senha marcadas `sensitive`
`terraform/terraform.tfvars.example`	Modelo das variáveis, sem valores reais
`terraform/.terraform.lock.hcl`	Versões exatas dos providers

Decisões. O estado do Terraform (`terraform.tfstate`) fica fora do Git porque guarda as senhas em texto. O assistente da Aiven sugere no primeiro acesso um serviço pago (`developer-1`); esse serviço foi apagado e o Terraform criou os planos gratuitos. A variável `nome_servico_pg` permite trazer um serviço já existente para o Terraform com `terraform import`. O CI roda `terraform fmt` e `terraform validate` a cada push.

5. Segurança das informações

Nenhuma credencial está no repositório público. Cada segredo fica num cofre próprio e só chega a quem precisa dele; o repositório contém apenas modelos sem valores reais (`.env.example`, `terraform.tfvars.example`, `secrets.toml.example`).

Credencial	Onde fica	Quem usa
Token da API da Aiven	`terraform/terraform.tfvars` local, ignorado pelo Git (ou variável `TF_VAR_aiven_api_token`)	Terraform
URI do administrador (`DATABASE_URL`) e do OpenSearch	`.env` local, ignorado, e **GitHub Actions Secrets**	ETL
URI do usuário somente leitura (`DASHBOARD_DATABASE_URL`)	`.streamlit/secrets.toml` local, ignorado, e **Streamlit Cloud Secrets**	Dashboard
Estado do Terraform (contém todas as senhas)	Só na máquina de quem provisionou, ignorado, com cópia privada	Terraform

Camadas de proteção

1. `.gitignore` bloqueia `.env`, `secrets.toml`, `terraform.tfvars`, `*.tfstate`, planos do Terraform e os microdados brutos.
2. O CI roda o **gitleaks** sobre todo o histórico do Git a cada push e falha se encontrar um token ou senha.
3. **Menor privilégio:** o dashboard público usa `dashboard_leitor`, que só pode fazer `SELECT`. A senha de administrador existe apenas no GitHub Actions.
4. **TLS obrigatório** em todas as conexões com a Aiven.
5. Saídas do Terraform com senha marcadas `sensitive`, que não aparecem no log.
6. SQL parametrizado no dashboard e nenhum dado pessoal identificável gravado (LGPD).

Verificação feita em 07/11/2026: `gitleaks` sobre os 6 commits e sobre `dados_tratados/` retornou “no leaks found”; `git ls-files` não lista nenhum `.env`, `tfstate` ou `tfvars`; um `DELETE` com `dashboard_leitor` no banco da Aiven foi recusado com `InsufficientPrivilege`.

O README (seção 13) também descreve o que fazer se uma credencial vazar: revogar o token, regenerar a senha do leitor com `terraform apply -replace` e trocar a senha do administrador no console.

6. Repositório do projeto

O repositório separa cada tipo de artefato numa pasta própria. As pastas em maiúsculas no comentário correspondem aos itens mínimos pedidos.

```
├── etl/                # TRATAMENTO: extração, limpeza, regras, carga
│   ├── sql/            # schema.sql (banco) e views.sql (indicadores)
│   └── tests/          # 25 testes das regras de negócio
├── terraform/          # INFRAESTRUTURA: arquivos .tf e lock
├── dados_tratados/     # BASE TRATADA: Parquet, CSV, MANIFESTO.json
├── docs/               # DOCUMENTAÇÃO: PDFs das entregas
├── README.md           # DOCUMENTAÇÃO principal (17 seções)
├── dashboard/          # visualização (Streamlit), próxima fase
├── .github/workflows/ # REPRODUÇÃO: CI e ETL mensal
├── requirements.txt    # REPRODUÇÃO: dependências com versão fixa
├── .env.example        # modelo de variáveis, sem segredos
└── .gitignore          # bloqueia segredos, tfstate e dados brutos
```

Os microdados brutos (~1,2 GB) não são versionados: o ETL os baixa de novo da fonte oficial, e a versão exata usada fica registrada pelo SHA-256.

7. Documentação (README.md)

O README foi reorganizado para seguir os tópicos pedidos. No topo há uma tabela que leva a cada entregável do Marco 2.

Tópico exigido	Seção do README	O que apresenta
Dados utilizados: fonte, identificação, período, características	3. Dados utilizados	4 fontes com identificador no portal; 2019–2024; volume, códigos, informação ignorada; tabela da versão original com SHA-256
Tratamento: problemas, decisões, transformações, justificativas	7. Tratamento realizado; 8. Processo de ingestão e ETL; 11. Regras de negócio	8 problemas com quantidade; 14 decisões com justificativa e impacto; etapas do pipeline; regras RN-00 a RN-10

Tópico exigido	Seção do README	O que apresenta
Modelagem: estrutura, estratégia, representação	9. Modelagem; 10. Dicionário de dados	Diagrama do esquema estrela, comparação relacional × não relacional, campos e tipos, quantidade armazenada
Infraestrutura: serviços, recursos, tecnologias	12. Infraestrutura	Serviços e planos, 7 recursos do Terraform (6 criados + 1 lido), arquivos, tecnologias com versão
Execução: ferramentas, reprodução, sequência	15. Execução e reprodução	Ferramentas com versão, sequência em 7 passos, comandos para Linux e Windows, como destruir
Segurança	13. Segurança da informação	Onde fica cada credencial, camadas de proteção, como verificar, o que fazer em caso de vazamento

A pasta `dados_tratados/` tem um README próprio com o conteúdo de cada arquivo, e `docs/` guarda os PDFs das entregas anteriores.

8. Escolhas tecnológicas e justificativas

Cada escolha partiu de duas restrições da base: **25 milhões de linhas** de entrada e um banco gratuito de **1 GB**.

Aspecto	Escolha	Alternativa considerada	Por que a escolha
Ferramenta de tratamento	Python + pandas	PySpark	O volume cabe num computador comum se lido em blocos; o Spark exigiria um cluster sem ganho real

Aspecto	Escolha	Alternativa considerada	Por que a escolha
Estratégia de processamento	Lote (*batch*) em blocos de 250 mil linhas, mensal e incremental	Streaming	A fonte é publicada uma vez por ano e revisada aos poucos; streaming não teria o que transmitir
Organização dos dados	Agregação prévia no grão ano × município × raça/cor × faixa	Guardar um registro por evento	Cabe em 15% do banco e atende à minimização da LGPD sem perder as análises do painel
Modelo de banco	Esquema estrela no PostgreSQL + índice no OpenSearch	Modelo 3FN; tabela única; só NoSQL	Consultas de soma com filtros cruzados são o caso típico do esquema estrela; chaves e `CHECK`s garantem a veracidade; o OpenSearch cobre a busca textual
Estrutura de código	Módulos por etapa (extract, transform, regras, load) + testes	Notebook único	Cada etapa é testada e reutilizada; o mesmo código roda local e no GitHub Actions
Armazenamento intermediário	Parquet por ano	CSV	Colunar, compactado e preserva os tipos das colunas; a base tratada inteira ocupa 13 MB
Infraestrutura	Aiven gratuita, provisionada por Terraform	Banco local; criar pelo console	Nuvem a custo zero, reproduzível e destruível com um comando

9. Resultado do Marco 2

O fluxo pedido está completo, e a camada de dados já está sendo usada pela fase seguinte: o dashboard publicado lê o banco da Aiven.

Etapa	Evidência
1. Dados públicos selecionados	12 arquivos do SIM e do SINASC 2019–2024, identificados por data de publicação e SHA-256 (README, seção 3)
2. Dados preparados e tratados	25.021.734 linhas lidas, 217 duplicatas removidas, 14 decisões de tratamento documentadas (seção 7)
3. Dados organizados por modelagem definida	Esquema estrela com 3 fatos e 11 dimensões (seções 9 e 10)
4. Dados armazenados em banco na nuvem	694.410 linhas e 158 MB no Aiven for PostgreSQL; 12.080 documentos no OpenSearch
5. Processo e infraestrutura documentados e versionados	`etl/`, `terraform/`, `dados_tratados/` e README no GitHub; CI aprovado no último commit

O ETL também está agendado no GitHub Actions para todo dia 5 e, em modo incremental, só reprocessa os anos que o Ministério da Saúde republicar, mantendo a base atualizada para as próximas fases.